

FIAP  ONI

08

DATA SCIENCE PATH



LISTA DE FIGURAS

Figura 1 - Road Map Data Science 1 5

Figura 2 - Road Map Data Science 2 6

Figura 3 - Road Map Data Science 3 8

Figura 4 - Road Map Data Science 4 10

Figura 5 - Road Map Data Science 5 12

Figura 6 - Road Map Data Science 6 14

Figura 7 - Road Map Data Science 7 15



SUMÁRIO

1 DATA SCIENCE PATH	4
2 MINERAÇÃO DOS DADOS (<i>DATA MINING</i>)	5
3 COMPREENSÃO DO NEGÓCIO	6
4 COMPREENSÃO DOS DADOS.....	8
5 PREPARAÇÃO DOS DADOS	10
6 MODELAGEM	12
7 AVALIAÇÃO E INTERPRETAÇÃO	14
8 <i>DEPLOY</i> E PUBLICAÇÃO	15
REFERÊNCIAS.....	16

1 DATA SCIENCE PATH

Segundo Carvalho et al. (2024), com base em Berman et al. (2018), os dados possuem um ciclo de vida semelhante ao de organismos biológicos, passando por etapas que vão desde o nascimento até uma fase ativa, podendo eventualmente "morrer" (serem removidos) ou permanecer "vivos" indefinidamente, dependendo de seu uso e relevância.

No contexto da ciência de dados, o ciclo de vida dos dados é essencial para entender como eles são criados, processados, analisados e armazenados ao longo do tempo. Uma das etapas mais importantes nesse processo é a mineração de dados, que atua como uma fase de exploração profunda dos dados ativos para extrair padrões, identificar tendências e gerar insights valiosos.

2 MINERAÇÃO DOS DADOS (*DATA MINING*)

Você sabe o que é mineração de dados? Pode não saber exatamente, mas com certeza já ouviu falar. *Data mining* é uma das maiores tendências atuais e se classifica como um conjunto de técnicas baseada em estatísticas e *machine learning* que objetivam extrair informações.

A mineração de dados pode ser definida como o processo para entender os requisitos de negócios utilizando a análise estatística e habilidades de aprendizado de máquina para extrair informações úteis dos dados e apresentá-las ao usuário. As informações dos dados não surgem magicamente; há todo um processo por trás disso, que vamos explicar ao longo desse capítulo.

Um projeto de ciência de dados consiste em seis fases, conforme ilustrado na figura a seguir. É um processo contínuo que tem o objetivo de melhorar os resultados de mineração de dados após a conclusão de cada ciclo, desde o entendimento do negócio até a fase de implantação.




Figura 1 - Road Map Data Science 1
Fonte: Elaborada pelo autor (2025)

3 COMPREENSÃO DO NEGÓCIO

Na primeira fase de um projeto, independentemente da área de aplicação, antes de abordar dados ou ferramentas, é necessário definir o que se pretende realizar e quais são as razões para atingir esse objetivo. No contexto da ciência de dados e áreas correlatas, essa fase envolve identificar claramente as perguntas que precisam de respostas e os objetivos que se deseja alcançar. Um entendimento claro do problema permite não apenas selecionar as ferramentas e abordagens adequadas, mas também garantir que os esforços estejam alinhados às expectativas e às necessidades do negócio ou do domínio específico.

Sem um entendimento sólido do problema, o risco de desenvolver soluções que não agreguem valor ou que abordem questões irrelevantes aumenta significativamente. Por isso, investir tempo nessa etapa é crucial para o sucesso de qualquer iniciativa.




Figura 2 - Road Map Data Science 2
Fonte: Elaborada pelo autor (2025)

Reservar um tempo para ter entendimento do negócio da empresa, ou da área solicitante do estudo, ajuda a determinar exatamente o que deve ser realizado. Isso é menos óbvio do que parece. Muitos profissionais aplicam tempo

na análise de dados apenas para descobrir que o gestor não estava particularmente interessado no problema que estava sendo investigado.

Nessa fase deve haver uma clara compreensão sobre:

- O problema que a gerência deseja resolver.
- Os objetivos do negócio.
- Restrições (limitações sobre o que pode ser feito, os tipos de soluções que podem ser usadas, quando o trabalho deve ser concluído e assim por diante).
- Impacto (como o problema e as possíveis soluções se relacionam com o negócio).

Neste momento, é fundamental alinhar expectativas, pois pode haver limitações na captura de certos dados, especialmente quando a fonte é externa à organização. Um exemplo disso são os dados de usuários em mídias sociais: se um perfil for privado, a quantidade de informações acessíveis será significativamente menor do que a de um perfil público.

4 COMPREENSÃO DOS DADOS

Essa fase busca coletar e entender as características dos dados, o que é fundamental para evitar problemas inesperados durante a próxima fase, que normalmente é a parte mais longa de um projeto. Os dados serão obtidos e ocorrerá uma verificação para ver se eles são apropriados para as necessidades do projeto.




Figura 3 - Road Map Data Science 3
Fonte: Elaborada pelo autor (2025)

Podem ser identificados problemas que irão nos levar de volta à fase de compreensão do negócio, como falhas no entendimento do negócio ou outro motivo para repensar metas e planos.

A fase de compreensão de dados é composta pela coleta de dados através de API's, ferramentas e *scripts*. Em seguida, ocorre a exploração e análise desses dados com mais detalhes.

Para cada variável, será observado o intervalo de valores e as distribuições para entender o seu comportamento ao longo do tempo. Para isso, é realizada a manipulação dos dados através de técnicas estatísticas básicas para verificações adicionais. A exploração de dados tem os seguintes objetivos:

- Familiarização com os dados.

- Identificação de sinais de problemas de qualidade de dados.
- Definição do cenário para as etapas de preparação de dados.

Um exemplo simples de pensar é em quais fatores aumentam, diminuem ou não fazem diferença no valor de uma casa. A quantidade de quartos faz diferença no valor do imóvel? Se sim, com o aumento da quantidade de quartos, o valor de venda aumenta ou diminui? E a quantidade de portas corta fogo, faz diferença no valor do imóvel? Existem dois dados que me dão as mesmas repostas? Existem dados duplicados?

A partir das respostas de perguntas desse tipo, conseguimos determinar se faz sentido usar aquele dado em etapas futuras.

Logo após a exploração, vem a análise com o objetivo de determinar se eles são bons o suficiente para dar suporte aos objetivos determinados.

Frequentemente, podem surgir problemas de qualidade dos dados a serem resolvidos. Em muitos casos, é possível seguir em frente, mas, às vezes, a qualidade é tão baixa que inviabiliza o plano, tornando necessário buscar alternativas. Alguns dos piores problemas incluem:

- Os dados necessários para a análise não existem (Eles nunca existiram ou foram descartados? Esses dados podem ser coletados e salvos para uso futuro?).
- Os dados existem, mas eles não podem ser acessados (Essa restrição pode ser superada?).
- Os dados apresentam problemas graves de qualidade (Muitos valores ausentes ou incorretos que não podem ser corrigidos).

Se esses problemas surgirem e não houver uma solução viável, pode ser necessário reconsiderar as metas ou ajustar os planos.

Desse modo, é nesse momento que começa o trabalho de mineração dos dados, pois devemos ser capazes de identificar quais são os dados importantes para a solução do problema e analisar sua qualidade. Identificar padrões e valores extremos também faz parte desse processo.

5 PREPARAÇÃO DOS DADOS

Após a compreensão dos dados, eles serão preparados.




Figura 4 - Road Map Data Science 4
Fonte: Elaborada pelo autor (2025)

Essa fase abrange todas as atividades para construir o conjunto de dados final a partir da base de dados brutos, ou seja, é feita a escolha dos dados que serão usados e, conseqüentemente, trabalhados. Além disso, serão analisados como os dados podem ser cruzados para resolver o problema da empresa, a preparação das bases de dados e a definição do formato que será necessário para a análise.

A fase de preparação provavelmente será a etapa mais trabalhosa de todas, pois irá envolver muito conhecimento, uma vez que serão analisados diversos detalhes relativos aos dados.

Essa fase é composta, basicamente, pelas seguintes atividades:

- Seleção;
- Limpeza;
- Construção;
- Integração;

- Formatação.

É improvável que os dados que você escolheu utilizar estejam perfeitamente limpos (sem erros). Você fará alterações, talvez rastreando fontes para fazer correções de dados específicas, excluindo alguns registros/colunas (itens de dados) ou deverá substituir alguns itens de dados por valores padrão.

Logo após esse processo, pode ser necessário derivar alguns novos campos (por exemplo, utilizar a data de entrega e a data em que o cliente fez um pedido para calcular quanto tempo o usuário esperou), agregar, formatar ou particionar os dados.

6 MODELAGEM

A modelagem é a parte do modelo de processo *Cross-Industry Standard Process for Data Mining* (CRISP-DM) que a maioria dos mineradores de dados mais gosta. Os dados já estão em boa forma e agora podemos pesquisar padrões úteis.




Figura 5 - Road Map Data Science 5
Fonte: Elaborada pelo autor (2025)

O maravilhoso mundo da ciência de dados oferece inúmeras técnicas de modelagem, mas nem todas atenderão às suas necessidades. Por conta desse fator, restrinja a lista com base nos tipos de variáveis envolvidas, na seleção de técnicas disponíveis em suas ferramentas e em quaisquer considerações de negócios que sejam importantes para você.

Por exemplo, muitas organizações preferem métodos com resultados fáceis de interpretar, portanto, árvores de decisão ou regressão logística podem ser aceitáveis, mas redes neurais provavelmente não seriam bem utilizadas.

Outros quesitos que interferem na escolha do resultado são o objetivo do projeto, quais dados possuem e, principalmente, a relação de precisão do resultado e o custo computacional.

Normalmente, o cientista de dados escolhe alguns modelos para testar e comparar os desempenhos. Há, também, a divisão dos dados em dois grupos:

para treinamento e para teste de modelo. Os dados de treinamento são utilizados para ajustar formas matemáticas ao modelo de dados. Já os dados de teste são usados durante o processo de treinamento do modelo para evitar o *overfitting*: fazer um modelo perfeito para um conjunto de dados, mas não para outro. Você também pode utilizar dados de validação, que não são usados durante o processo de treinamento do modelo, para um teste adicional.



7 AVALIAÇÃO E INTERPRETAÇÃO

Nas primeiras quatro fases do modelo de processo CRISP-DM, você explorou os dados e encontrou padrões. Agora precisamos nos perguntar: os resultados são bons? Precisamos avaliar não apenas os modelos criados, mas também o processo usado para os criar e seu potencial para uso prático.




Figura 6 - Road Map Data Science 6
Fonte: Elaborada pelo autor (2025)

Nessa fase, você avaliará o valor de seus modelos para atender às metas de negócios que iniciaram o processo de mineração de dados. Você procurará quaisquer razões pelas quais o modelo não seria satisfatório para uso comercial. Se possível, também testará o modelo em uma aplicação prática, para determinar se ele funciona tão bem em um ambiente de produção quanto nos testes.

Agora que já explorou os dados e desenvolveu modelos, reserve um tempo para revisar seu processo. Essa é uma oportunidade para identificar problemas que você pode ter deixado passar e que podem destacar falhas no trabalho realizado, permitindo que você corrija o problema antes da implantação. Aproveite também para refletir sobre formas de aprimorar seu processo em projetos futuros.

8 DEPLOY E PUBLICAÇÃO

Essa é a fase em que a mineração de dados realmente faz a diferença. Aqui, não importa o quão impressionantes sejam suas descobertas ou o quão bem seus modelos se ajustem aos dados, se você não usar essas informações para aprimorar a forma como faz negócios.




Figura 7 - Road Map Data Science 7
Fonte: Elaborada pelo autor (2025)

Quando o modelo estiver pronto para uso, você precisará de uma estratégia para colocá-lo em prática no seu negócio. Após a entrega, o trabalho não termina, pois é necessário garantir o monitoramento e a manutenção à medida que o projeto é integrado ao uso diário. eles são integrados ao uso diário.

Além disso, um resumo do relatório final é apresentado em uma reunião com a equipe estratégica. Essa é uma oportunidade para abordar quaisquer questões em aberto.

Depois dessa análise, agora vocês conhecem todo o percurso que devemos seguir na ciência de dados!

REFERÊNCIAS

CARVALHO, ANDRÉ C.P.L.F. **Ciência de dados:** Fundamentos e aplicações. 1 ed. Rio de Janeiro: LTC editora, 2024.

MARQUESONE, Rosangela. **Big Data:** Técnicas e tecnologias para extração de valor dos dados. São Paulo: Casa do Código, 2016.

PROVOST, FOSTER; FAWCETT, TOM. **Data Science para Negócios.** Rio de Janeiro: Alta Books, 2016.

SANTOS, Maribel Yasnuba; COSTA, Carlos. **Big Data Concepts, Warehousing and Analytics.** Concepts, Warehousing, And Analytics. Giustrap, Dinamarca: FCA, 2019.