

11

PREPARANDO OS DADOS



LISTA DE FIGURAS

Figura 1 – <i>Data Wrangling</i>	4
Figura 2 – Limpeza de dados	5

EMAP

SUMÁRIO

1 PREPARANDO OS DADOS	4
1.1 Introdução	4
1.2 Características do Data Wrangling	4
1.3 Características do Data CLEAN	5
1.3.1 Benefícios da limpeza de dados.....	5
1.4 Principais atividades utilizadas na preparação dos dados	6
1.4.1 Tratamento de valores ausentes (missing).....	6
1.4.2 Tratamento de valores atípicos (outliers)	6
1.4.3 Conversão de tipos de dados.....	7
1.5 variáveis	7
1.5.1 Variáveis quantitativas ou numéricas	8
1.5.2 Variáveis qualitativas ou categóricas	8
1.6 Checagem e remoção de multicolinearidade	9
1.7 Normalização de dados numéricos	9
1.8 Conversão de dados categóricos em formato numérico (encoding)	9
CONCLUSÃO.....	10
REFERÊNCIAS.....	11

1 PREPARANDO OS DADOS

1.1 Introdução

A preparação (ou manipulação) dos dados também é conhecida como *data munging* ou *data wrangling*. No processo de ciência de dados, as atividades de preparação dos dados podem representar de 50% a 80% do tempo total dedicado ao projeto, e as técnicas utilizadas influenciam diretamente os resultados obtidos.



Figura 1 – Data Wrangling
Fonte: Adaptada de Villegas (2025)

Existem uma série de tarefas e processos pelos quais os cientistas de dados devem passar para preparar seus dados para análise. As tarefas de *data wrangling* e de *data cleaning* são importantes nessa preparação. No entanto, devido às suas funções semelhantes no *pipeline* de dados, os dois conceitos geralmente são confundidos.

1.2 Características do Data Wrangling

Essa etapa é uma parte essencial da preparação dos dados. As principais características desse processo são:

- Melhorar a facilidade de acesso aos dados.

Preparando os dados

- Possibilitar menor tempo para *insights*.
- Maior eficiência quando se trata de tomada de decisões orientada por dados.

1.3 Características do *Data CLEAN*

A fase *data clean*, também conhecida como limpeza de dados, é o processo de localizar e corrigir dados imprecisos de um determinado conjunto ou fonte de dados. O objetivo principal é identificar e remover inconsistências sem excluir os dados necessários para produzir *insights*. É importante remover essas inconsistências para aumentar a validade do conjunto de dados.

A limpeza dos dados engloba diversas atividades, como identificar registros duplicados, preencher campos vazios e corrigir erros estruturais. Essas tarefas são cruciais para garantir que a qualidade dos dados seja precisa, completa e consistente.



Figura 2 – Limpeza de dados
Fonte: Freepix (2025)

1.3.1 Benefícios da limpeza de dados

Há uma ampla gama de benefícios que podem levar a uma maior eficiência operacional, como:

- Eliminação de erros.

Preparando os dados

- Redução de custos relacionados a erros.
- Melhoria da integridade dos dados.
- Garantia da qualidade de informação para a tomada de decisões.

Ao comparar os benefícios de cada um, fica claro que os objetivos por trás da organização e limpeza de dados são consistentes entre si. Cada um deles visa melhorar a facilidade de uso quando se trata de trabalhar com dados, tornando a tomada de decisões orientada por dados mais rápida e mais eficaz.

1.4 Principais atividades utilizadas na preparação dos dados

Há uma série de técnicas, procedimentos e ferramentas utilizadas na fase de preparação dos dados. Vamos apresentá-las a seguir.

1.4.1 Tratamento de valores ausentes (*missing*)

Considere que foi realizada uma coleta de um banco de dados para trabalhar em um projeto de prevenção de doenças. Em algumas colunas, pode ter ausência de valores porque o sistema que cadastrou os dados não previa a obrigatoriedade para aquele determinado campo ou que, durante a coleta dos dados, houve algum problema que provocou a omissão dos dados.

Para tratar essas situações, há uma série de técnicas, por exemplo, a remoção da linha na qual há ausência de um dado. Isso, de certa forma, pode ser impactante, uma vez que será removida uma determinada quantidade de dados. Outra técnica é utilizar a “imputação”, ou seja, determinamos a média ou a mediana dos valores da coluna e inserimos o valor encontrado onde há ausência de valores.

1.4.2 Tratamento de valores atípicos (*outliers*)

Os valores atípicos influenciam nas médias dos dados e, conseqüentemente, irá influenciar na distribuição normal, já que a maioria dos algoritmos de *machine learning* “esperam” receber os dados distribuídos.

Preparando os dados

Se houver valores extremos em uma determinada coluna do conjunto de dados, esses valores devem ser tratados, seja removendo-os ou realizando um estudo adicional, de acordo com objetivo do projeto de análise preditiva, pois, se estamos estudando a detecção de anomalias, talvez o valor extremo seja exatamente o que se procura.

De acordo com o teorema central do limite, os dados estarão sempre próximos da média. Nesse contexto, a presença de valores extremos, ou seja, que estão muito distantes da média, pode impactar diversas estatísticas e, conseqüentemente, a modelagem preditiva. Por isso, é essencial tratar esses eventos adequadamente.

Para saber mais sobre o teorema central do limite, veja o vídeo:
https://www.youtube.com/watch?v=WpRsFHUj2_E&t=76s.

Uma dica importante é que todas as decisões devem ser documentadas e justificadas.

1.4.3 Conversão de tipos de dados

Dependendo da ferramenta que você está utilizando, ela pode não identificar corretamente uma coluna como sendo do tipo numérico ou decimal, o que exigirá que você faça conversões nos dados. Algumas dessas conversões podem resultar em perda de informações. Por exemplo, ao converter uma coluna com valores decimais para valores inteiros, pode ocorrer arredondamento, o que pode levar à perda de dados.

1.5 variáveis

Uma variável é uma característica que pode ser medida e pode assumir diferentes valores. Altura, idade, renda, país de nascimento, notas obtidas na escola e tipo de moradia são exemplos de variáveis. Elas podem ser classificadas em duas principais categorias: categóricas e numéricas. Cada categoria é, então, classificada em duas subcategorias: nominal ou ordinal, para variáveis categóricas e discreta ou contínua, para variáveis numéricas.

1.5.1 Variáveis quantitativas ou numéricas

Uma variável numérica, também chamada de variável quantitativa, é uma característica quantificável cujos valores são números (exceto quando os números são códigos que representam categorias).

- **Variável contínua:** Ocorre se ela pode assumir um número infinito de valores reais dentro de um determinado intervalo. Geralmente as medidas são obtidas por meio da utilização de algum instrumento. Exemplos: altura, peso, tempo, idade etc.
- **Variável discreta:** Admite apenas um intervalo finito de valores reais dentro de um determinado intervalo. Exemplos: quantidade de dependentes, número de plaquetas no sangue por microlitro, quantidade de doces consumidos por dia etc.

1.5.2 Variáveis qualitativas ou categóricas

São as variáveis que representam uma classificação dos indivíduos, ou seja, não possuem valores quantitativos e são definidas por várias categorias.

- **Variável nominal:** É aquela que descreve um nome, rótulo ou categoria sem ordem natural. Gênero e tipo de moradia são exemplos de variáveis nominais.
- **Variável ordinal:** Apresenta valores que são definidos por uma relação de ordem entre as diferentes categorias. Por exemplo, a variável "comportamento" é ordinal porque a categoria "excelente" é melhor que a categoria "muito bom", que é melhor que a categoria "bom" etc. Existe algum ordenamento natural, mas é limitado, pois não sabemos em que medida o comportamento "excelente" é melhor do que o comportamento "muito bom".

1.6 Checagem e remoção de multicolinearidade

Multicolinearidade é quando temos duas colunas dentro do conjunto de dados que representam exatamente a mesma informação; é como se o dado fosse duplicado e essa situação pode influenciar negativamente o modelo. Então, temos que verificar a existência de multicolinearidade por meio da aplicação de alguns testes para remover o atributo posteriormente.

Caso queira saber mais sobre multicolinearidade, acesse o link:
<http://ibm.com/br-pt/think/topics/multicollinearity>.

1.7 Normalização de dados numéricos

Para que os dados possam ser apresentados ao modelo, é necessário que estejam normalizados, ou seja, com média igual a 0 e desvio padrão igual a 1. Na maioria das situações, os dados não estarão normalizados, portanto, é fundamental testar a normalidade antes de avançar para a etapa de modelagem.

1.8 Conversão de dados categóricos em formato numérico (*encoding*)

Os algoritmos de *machine learning* não trabalham com palavras, pois trabalham com números. Portanto, se temos dados no formato categórico (texto, por exemplo) temos que converter para uma representação numérica que seja significativa. Esse processo é chamado de *encoding*. Portanto, os dados categóricos devem ser convertidos para o formato numérico antes que eles sejam submetidos para um algoritmo de *machine learning*.

CONCLUSÃO

O processo de *data munging* pode auxiliar na diminuição do tempo gasto durante a análise de dados. Ele ajuda a descobrir as informações mais relevantes e, posteriormente, suporta o processo de análise de dados para que menos tempo seja consumido na obtenção de resultados mais confiáveis.

EVANS

REFERÊNCIAS

PROVOST, Foster; FAWCETT, Tom. **Data Science para Negócios**. Rio de Janeiro: Alta Books, 2016.

SANTOS, Maribel Yasnuba; COSTA, Carlos. **Big Data Concepts, Warehousing and Analytics**. Concepts, Warehousing, And Analytics. Giustrap, Dinamarca: FCA, 2019.

VILLEGAS, Fabyio. **Data Wrangling: What It Is & Steps to Follow**. Question Pro, s. d. Disponível em: <<https://www.questionpro.com/blog/data-wrangling/>>. Acesso em: 02 abr. 2024.